

日本語省略質問に対する検索・クエリ拡張手法の体系的評価

井原 惇宏¹ ジェプカ ラファウ²

¹ 北海道大学大学院情報科学院 ² 北海道大学大学院情報科学研究院

Abstract

We investigate how information omission affects Japanese document retrieval and how retrieval and query expansion methods respond to it. From 306 candidates based on JDocQA, human evaluation retained 276 queries covering three grammatical cases and four semantic categories. We compare seven methods on retrieval of the original evidence page from a collection of 510 pages, using document-grouped validation. Omission reduced mean reciprocal rank (MRR) across all five methods evaluated on both original and omission queries. Weighted sparse-dense fusion achieved the highest MRR of 0.8460 on omission queries, compared with 0.8333 for BM25, although the difference was not statistically significant. For Query2doc-style expansion, increasing the weight of the remaining query terms from one to five raised MRR from 0.8158 to 0.8423 with BM25 parameters and generated text held fixed. Selecting retrieval methods by gold omission category did not outperform selecting a single method across categories. These results highlight the importance of preserving the contribution of remaining query terms in expansion and show that omission categories alone did not yield better method selection.

1 はじめに

検索拡張生成 (Retrieval-Augmented Generation; RAG) [8] では、質問に関連する文書を検索し、生成モデルへ与える。質問から対象を特定する情報が省略されると、正解根拠への到達が難しくなる可能性がある。佐々木・山本は JDocQA を用い、省略が密検索性能を低下させることを示した [16]。一方、既存の検索・拡張手法がどの条件で省略の影響を緩和するかは十分に明らかでない。

本稿で扱う「曖昧クエリ」は、JDocQA の正解回答と根拠ページが付与された質問から、格や意味役割のカテゴリに基づいて情報の一部を省略したクエリであり、以降「省略質問」と呼ぶ。省略後も残る情報だけで検索対象を特定できる場合と、特定が難しくなる場合がある。本稿では、元質問の根拠ページを検索できるかを評価する。JDocQA [10] に基づく 7 カテゴリ・276 件の省略質問で、クエリ拡張を組み合わせた方式も含む 7 種類の検索手法を比較し、以下を検証する。(RQ1) 省略による検索性能の低下は検索手法間でどう異なるか、(RQ2) どの検索手法が高い性能を示し、その利点は省略に特有か、(RQ3) 省略カテゴリ別の検索手法選択は全カテゴリ共通の検索手法選択を上回るか。

本稿の貢献は、(1) 格と意味役割の二つの観点から、7 カテゴリの人手評価済み省略質問データセットを構築すること、(2) 省略質問に対する 7 種類の検索手法の性能を比較す

ること、(3) 省略カテゴリ別の検索手法選択の限界を検証・考察することである。

2 関連研究

佐々木・山本は、日本語 RAG 検索における省略由来の曖昧クエリを対象とし、省略が密検索の Recall を低下させることに加え、検索スコアの分散と上位文書の意味的一貫性が曖昧性検知の手掛かりになることを示した [16]。同研究は、日本語の文書質問応答データセット JDocQA [10] から 106 質問を抽出し、質問から主語・目的語・修飾語等を省略した条件を検証している。これは省略質問を検索時点で検知し、不足情報の確認や補完へ接続する重要な問題設定である。一方、同研究の検索実験は密検索を中心としており、省略の種類と、異なる検索・改善手法との関係には体系的比較の余地が残る。

日本語では、文脈から回復可能な述語の項が明示されない項省略が広く生じる。Ishizuki らは日本語均衡コーパスから 2,000 件を超える項省略判断を収集し、省略可否とその言語的要因を分析した [5]。また、日本語の述語項構造・ゼロ照応解析では、省略された項をガ格 (主格)、ヲ格 (対格)、ニ格 (与格) に分けて同定・解析する枠組みが用いられている [12]。これらは省略を述語に対する項の関係から捉える知見である。これに対し、検索への影響は、省略された情報が人物・組織、場所・管轄、時間、対象・内容・属性のいずれかという意味内容によっても異なり得る。本研究では、前者の格に基づく 3 分類と、後者の意味内容に基

づき操作的に定めた4分類を同一の分類体系とはみなさず、二つの観点から省略の影響を分析する。

情報検索には、語彙的一致を利用する疎検索と、質問・文書の意味表現を用いる密検索がある。本研究では、疎検索の代表として BM25 [11]、密検索の代表として密ベクトル検索 [6] を扱う。両者は省略後に残る検索信号が異なるため、省略に対する頑健性も異なる可能性がある。さらに、両検索器の相補性を利用する方法として、順位を統合する Reciprocal Rank Fusion (RRF) [2] と、正規化スコアの線形統合を比較する。

不足した検索信号を補う別の方法がクエリ拡張である。疑似適合フィードバックは初回検索の上位文書から適合モデル [7] を推定し、RM3 はこれを元クエリと補間して再検索する [1]。Query2doc は、大規模言語モデルが生成した疑似文書を元クエリへ連結する [15]。原研究では MS MARCO [9]、TREC Deep Learning Track [3]、BEIR [13] 等で改善が報告されている。一方、省略質問では不足した具体的実体を一意に復元できるとは限らず、初回検索や生成内容が誤れば、追加語が検索意図を変えるクエリドリフトを生じ得る。

以上を踏まえ、本研究は佐々木・山本の問題設定を継承し、省略質問に対して7種類の検索・改善手法を共通のデータ・分割・評価指標で比較し、正解カテゴリを追加入力する方式は区別する。さらに、二つの観点から定めた7カテゴリについて性能差と失敗要因を調べ、省略カテゴリだけで有効手法を選択できるかを検証する。本研究の目的は、新規検索器を提案することではなく、既存手法が日本語省略質問へ移転する条件と限界を明らかにすることである。この分析は、将来的に質問文だけでなく検索スコア、検索器間の不一致、上位文書の一貫性等を用いて検索失敗を検知し、必要な場合だけ補完や確認質問へ接続する選択的な検索処理の基礎となる。

3 データセット構築

3.1 元データと省略生成

本研究では、検索評価用データセットの元質問と検索対象文書を JDocQA から構築した。構築した省略質問データセットを GitHub で公開している^{*1}。JDocQA 収録質問のうち、回答が文章で記述され、回答不能理由がなく、画像のみを根拠としない 510 質問を候補母集団とした。このうち、先行研究と共通する validation/test split 由来の 106 件を基本集合とし、格省略の候補を確保するために train split 由来の 404 質問を追加した。元質問と正解回答は変更せず、質

問末尾の定型的な回答指示「解答は自由に記述してください。」のみを除去した。

格省略は、日本語統合解析器 KWJA [14] (2.5.1, base モデル, rhoknp 1.8.0) の述語項構造解析を用いて、明示されたガ格・ヲ格・ニ格の項を文字列上から機械的に削除した。解析格と表層助詞が一致し、項が述語へ直接係り、項に修飾句が付かず、削除位置を一意に復元できる候補だけから各格 40 件、計 120 件を選んだ。ニ格、ガ格、ヲ格の順に、seed 20260716 と候補 ID のハッシュ値による決定的な順序で抽出し、格省略 120 件内で元質問の重複を避けた。意味役割による省略は、人物・組織、場所・管轄、時間、対象・内容・属性の4カテゴリとした。固定 106 質問に対し、gpt-5-mini とカテゴリ定義を含む意味役割 4 カテゴリ生成プロンプト (付録 A) で候補を生成した。モデルには元質問、PDF メタデータ、正解回答、根拠本文の先頭 3,000 文字を与え、出力は元質問中の明示表現の削除と最小限の文法修正に限定するよう指示した。この指示への出力の適合を保証するものではなく、追加監査で規則から外れる編集も確認された (付録 D)。最大出力は 6,000 token (temperature・seed 未指定) である。カテゴリは元質問内の意味役割で排他的に付与し、回答・根拠からの情報追加は禁止した。人物・組織 39 件、時間 46 件、場所 51 件は生成候補を全件使用し、対象・内容・属性は seed 20260716 とカテゴリ・質問 ID・省略後質問のハッシュ値による順序で 50 件を抽出した。意味役割省略は計 186 件である。各カテゴリの定義と実例は付録 C に示す。

3.2 人手評価と選別

格省略 120 件と意味役割省略 186 件の計 306 質問を 4 バッチへ分け、クラウドワークス^{*2}で募集した 14 名が評価した。主評価の 12 名は 1 人 76-77 件を担当し、各質問を独立した 3 名が評価した。固定報酬は 1 人当たり税抜 3,000 円、想定作業時間は約 2 時間とした。生成 AI・自動評価ツールの使用と評価者間の相談を禁止し、未入力、不正値、固定列の改変、不自然な一律回答の有無を確認した。自然性は 1 (自然)、2 (やや不自然)、3 (不自然)、回答可能性は 1 (回答可能)、2 (条件付きで回答可能)、3 (回答困難) の 3 段階とした。回答可能性の 2 は、正解回答が候補になるが見出し・周辺文脈・対象の補足が必要な場合である。評価者には元質問、省略後質問、省略情報、正解回答を提示し、回答可能性では「適切な文書がすでに特定され、参照できる」と仮定した。これは検索可能性や、質問単独での意

^{*1} <https://github.com/Language-Media-Lab/Japanese-omission-query-retrieval>

^{*2} クラウドソーシングサービス「クラウドワークス」:
<https://crowdworks.jp/>

表 1 評価用省略質問のカテゴリ別件数.

分類	カテゴリ	件数
格解析	ガ格	36
	ヲ格	32
	ニ格	32
意味役割	人物・組織	38
	場所・管轄	49
	時間	42
	対象・内容・属性	47
合計		276

図の一意性を測る評点ではない. 意味役割 4 カテゴリではカテゴリ名を提示し, 妥当性を 1 (妥当), 2 (判断が分かれる), 3 (不適切) で評価した. 元の 3 名で評価 1 と 3 が混在した 76 質問には, 残る 2 名によるブラインド評価を追加した. 通常項目は 3 名, 追加対象は 5 名の中央値を合意値とした. 自然性または回答可能性の中央値が 3 の 30 件を除外し, 276 件を検索実験に用いた. カテゴリ妥当性は選別条件には使用せず, カテゴリ別解析時の注意情報として保持した. 評価対象 186 件中, その中央値が 3 の 3 件中 1 件は上記基準で除外され, 2 件 (EVAL-0053, EVAL-0256) は 276 件に含まれる. 公開先と本稿の訂正実験の対応は付録 G に示す. この 2 件を含むカテゴリラベルの不確実性は, カテゴリ別分析の限界として扱う.

表 1 に最終件数を示す. 276 省略質問は 176 元質問から生成され, 176 個の根拠文書を共有する. 同じ元質問から複数の省略質問を作るためであり, 検索コーパスの文書重複とは異なる. この依存を無視したクエリ単位分割は, 類似内容が開発・評価の双方へ入る漏洩を生じ得るため, 以降の重み選択とルーティングでは根拠文書単位の 5-fold 分割を用いる.

3.3 評価者間一緻度

順序尺度の Krippendorff の α [4] を, 評点の周辺度数に基づく順序距離と, 項目ごとの評価人数を考慮した一致行列から求めた. 表 2 は初回 3 名の全候補に対する結果である. 自然性と回答可能性の一致は十分に高いとはいえず, 評価基準の解釈差が残る. カテゴリ妥当性のペア一致率は 83.2% だが, 評点 1 が 503/558 評価 (90.1%) に集中し, 偶然一致を補正する α は 0.1048 にとどまる. したがって, 中央値 3 の項目が少ないことは, 高い評価者間一致を意味しない. また, 評点 1・2・3 の三者分裂でも中央値は 2 となり, 多数決とは異なる. 追加対象では自然性・回答可能性が 76 件, カテゴリ妥当性が 44 件である. 同じ追加対象で初回 3 名と 5 名を比較した α は, 自然性 0.1089 から 0.2189,

表 2 初回 3 名の一致度. 一致率は同一質問内の評価者ペアが同じ評点を付けた割合 (%).

評価軸	質問数	α	一致率
自然性	306	0.5116	68.5
回答可能性	306	0.3793	55.0
カテゴリ妥当性	186	0.1048	83.2

回答可能性 -0.0748 から 0.0732 , カテゴリ妥当性 -0.0454 から 0.0970 となった. 初回の強い不一致に基づく選択集合であり, 全候補とは分布が異なる. 評価者構成も変わるため, この差を評価者自身の一致が改善した因果効果とは解釈しない. 生成方式別の値は付録 D に示す.

4 検索手法と評価設定

4.1 文書・評価指標・分割

JDocQA の根拠ページ 1 ページを 1 文書とし, 510 文書を検索対象とする. 省略前の質問に付与された正解ページを, 省略後の質問でも検索できるかを評価する. 検索対象には, 同じページや本文が完全に一致する文書の重複はない.

主指標を Mean Reciprocal Rank (MRR), 補助指標を Recall@ k (以下 $R@k$; $k = 1, 3, 5, 10$) とする. MRR は全 510 文書中の正解順位の逆数を 276 省略質問で等重み平均する. 1 正解条件での $R@k$ は, 正解文書が上位 k 件に含まれる質問の割合である. 一つの元質問から複数の省略質問を作成しているため, 元質問ごとに平均してから全体を平均する補助集計も行った (付録 F). 同じ根拠文書に対応する質問が調整用と評価用の両方に入らないよう, 根拠文書単位でデータを 5 分割した. 各分割を順に評価用とし, 残りの 4 分割をパラメータの調整用に用いる. 同点スコアは文書 ID 順で解決する. 元質問用の疑似文書は生成していないため, 省略前後比較は密検索, BM25, RM3 型, RRF, 重み付き疎密統合の 5 手法に限定する.

4.2 検索・拡張手法

密検索は text-embedding-3-small (1,536 次元) の埋め込みを L2 正規化し, 内積で順位付けする. BM25 は NFKC 正規化 (全角・半角等の互換文字を統一), 小文字化, 空白除去後の文字 bigram を用いる. 外部形態素辞書に依存せず, 同一規則を日本語・英数字へ適用するためである. 本稿の主比較では, 質問中の bigram の出現回数 $c_q(t)$ を線形重みとして各語の BM25 寄与に掛ける. 質問語頻度の扱いを BM25 単独, 疎密統合, RRF, RM3 型の初回検索で揃える.

RM3 型は初回検索上位 10 文書から適合モデル [7, 1] を推定し, 選んだ上位 bigram 分布と質問の語頻度分布を補間して重み付き BM25 で再検索する. 文書の重み推定に Dirichlet 平滑化 ($\mu = 1000$) を用いる. 標準的な単語単位のクエリ尤度検索による RM3 の厳密な再現ではない.

Query2doc 型は、省略質問から gpt-5-mini と日本語の 4 例を用いたプロンプト (4-shot) で疑似文書を生成し、検索語を拡張する。通常版は省略質問のみを入力し、カテゴリ条件付き版は正解の省略カテゴリ名と定義も与える。各検索条件で同じ保存済み生成文を用いた。プロンプトと生成条件の詳細は付録 B に示す。

元の質問語が生成文に埋もれないよう、原研究 [15] にならって質問語の重みを 5 倍にする。本実装は質問と疑似文書を別々に bigram 化し、

$$w(t) = nc_q(t) + c_p(t), \quad n = 5 \quad (1)$$

を BM25 の質問語重みとする。\$c_p(t)\$ は疑似文書中の語頻度である。反復境界や [SEP] に由来する人工的な bigram を避けるため、文字列の反復連結ではなく頻度を加算する。\$n = 1\$ を補助条件とする。

RRF は密検索と BM25 の順位を \$1/(k+r)\$ の和で統合する。重み付き疎密統合は各質問について両検索器の全文書スコアを最小最大正規化し、

$$s(d) = \alpha s_{\text{dense}}(d) + (1 - \alpha) s_{\text{BM25}}(d) \quad (2)$$

で統合する。以降、本文・図表とも「密検索」「重み付き疎密統合」の表記を用いる。

4.3 パラメータ選択と統計比較

検索性能は、BM25 の設定値や疎密統合の混合比率などによって変わる。そこで、特定の固定値だけに比較結果が依存しないよう、主比較では各検索手法のパラメータを調整してから評価する。密検索は固定した埋め込みモデルを用いる。各回の調整用 4 分割で省略質問の MRR が最も高い設定を選び、その設定を評価用の 1 分割に適用する。評価用の正解情報は設定の選択に用いない。これを 5 回繰り返して、全質問の評価結果を集計する。省略前後の比較では、元質問にも省略質問と同じ設定を用いる。質問語の重み付けの影響を調べる補助比較では、他のパラメータと生成文を固定する。探索する値と候補数は付録 H に示す。

検索手法間の差は、同じ質問に対する結果を対応付けて検定する。同じ根拠文書から作られた質問の依存を考慮し、根拠文書単位で検定と 95% 信頼区間の推定を行う。主比較では各検索手法と BM25 の MRR 差を調べ、複数の比較による偶然の有意差を抑えるため Holm 補正を用いる。また、BM25 に対する利得を省略前後で比較し、その利得が省略時に大きくなるかを調べる。統計処理の詳細も付録 H に示す。

表 3 調整済み条件における元質問・省略質問の MRR。差は省略後から元を引いた値。

手法	元質問	省略質問	差
密検索	0.7702	0.7056	-0.0646
BM25	0.8734	0.8333	-0.0401
RM3 型	0.8721	0.8200	-0.0521
RRF	0.8446	0.8073	-0.0373
重み付き疎密統合	0.8878	0.8460	-0.0418

5 結果

5.1 省略前後の性能と頑健性

表 3 に、元質問と省略質問に対する各手法の MRR を示す。密検索の MRR は 0.7702 から 0.7056、BM25 は 0.8734 から 0.8333 へ低下した。R@1 はそれぞれ 72.1% から 65.6%、85.5% から 80.8% である。重み付き疎密統合は元質問でも BM25 を上回るため、省略質問での高性能だけから省略特有の頑健性とはいえない。ここでいう利得は、重み付き疎密統合の MRR から BM25 の MRR を引いた値である。利得は元質問で 0.0144、省略質問で 0.0127 となり、疎密統合の上乗せ効果が省略時に大きくなる傾向は見られなかった。また、省略による低下幅は元質問での性能水準にも左右される。元質問で高い性能を示す手法ほど同じ割合の低下でも差が大きく見えるため、低下幅だけで手法の頑健性や優劣を判断せず、省略後の性能も合わせて比較する必要がある。図 1 はカテゴリ別 R@1 の差を示す。各カテゴリは 32–49 件であり、同じ根拠文書を共有する質問も含む。カテゴリごとの件数が限られるため、図の値はカテゴリごとの傾向を示す参考値として解釈する。図 1 の BM25 では、ガ格の R@1 差は 0 であり、時間カテゴリでは省略後の R@1 が元質問と同じである。これは今回の標本で上位 1 位の正解数が変わらなかったことを示すが、カテゴリ全体で省略の影響がないことを意味しない。MRR や R@3 以降では順位変化が生じているカテゴリもある。

5.2 検索改善手法の比較

表 4 に、7 種類の検索手法を同じ検索対象と評価質問で比較した結果を示す。重み付き疎密統合は MRR 0.8460 で最も高く、BM25 は 0.8333 であった。R@1 はカテゴリ条件付き Query2doc 型が 81.9% で最も高く、R@3 と R@5 は重み付き疎密統合が最も高かった。手法によって得意な指標が異なるため、単一の手法がすべての指標で優れるわけではない。この結果は、省略質問では疎検索と密検索を組み合わせる方式、またはカテゴリ情報を用いたクエリ拡張が有力な候補になることを示す。ただし、本研究のデータと実装条件で得られた比較であり、手法の一般的な優劣を直接示すものではない。




図1 調整済み条件でのカテゴリ別 R@1 差 (省略 - 元). 誤差棒は根拠文書単位の 95% クラスター・ブートストラップ区間であり, 多重比較調整はしていない.

表4 省略質問に対する7種類の検索手法の比較. MRR は 0-1, R@k は %. 太字は列内最高値.

手法	MRR	R@1	R@3	R@5	R@10
密検索	0.7056	65.6	73.2	75.7	80.1
BM25	0.8333	80.8	84.1	86.2	88.4
RM3 型	0.8200	79.3	83.0	84.4	87.7
Query2doc 型	0.8382	81.2	84.8	86.6	88.8
Query2doc 型 (正解カテゴリあり)	0.8447	81.9	85.1	87.3	90.2
RRF	0.8073	75.4	84.1	87.7	90.2
重み付き疎密統合	0.8460	81.2	86.2	88.0	90.2

表5 固定 BM25 条件での質問語重みの比較. 同じ生成方式の重み 1・5 間でキャッシュを共有し, 条件付き版は正解カテゴリを利用する.

条件	MRR	R@1 (%)
BM25	0.8278	80.1
通常版, 重み 1	0.8158	78.3
通常版, 重み 5	0.8423	81.9
条件付き版, 重み 1	0.8122	77.5
条件付き版, 重み 5	0.8388	81.2

5.3 質問語の重み付けと拡張

表5ではBM25の $k_{1,b}$ と疑似文書を固定し, 式1の n だけを変えた. 通常版は $n=1$ のMRR 0.8158から $n=5$ の0.8423へ上昇した. 固定BM25 (0.8278)と比べても, 重み5の通常版は0.8423, カテゴリ条件付き版は0.8388となり, 質問語の重み付けが結果に影響することが分かる. この比較はBM25の設定値と生成文を固定した補助分析であり, 重み付けの効果を他のモデルやデータへそのまま一般化するものではない. 質問語の重み付けは, 質問と疑似文書を別々に文字bigram化し, 質問語の出現回数を重み5で加算する現在の条件で評価した. この結果は, 本研究の日本語プロンプトと文字bigram実装に基づくものである.

5.4 クエリ単位のエラー分析

図2に主比較における正解順位の変化を示す. 調整済みBM25に対し, 重み付き疎密統合は42件を改善し9件を悪化させた. 通常Query2doc型は25件・22件, カテゴリ条件付き版は29件・21件であった. Top-1だけを見るとRM3型は回復2件・悪化6件, 通常版は4件・3件, カテゴリ条件付き版は6件・3件である. これら拡張3方式の少なくとも一つが該当する質問を重複除去すると, 回復7件・悪化8件となった. 拡張によって改善する質問と悪化する質問の両方があり, 改善が一方に生じるわけではない. 順位変化だけから, 誤った具体化, 一般語の追加, 質問語の相対的寄与の低下などの原因を一つに特定することはできない. 一方, 拡張語によって検索意図がずれる語彙的クエリドリフトが, 一部の失敗に関連した可能性はある.

5.5 カテゴリ別ルーティング

候補はBM25, RM3型, Query2doc型2方式, 重み付き疎密統合の5手法とする. 外側評価foldを完全に除いた開発集合で, 根拠文書単位の内側4-foldを作成した (seedは20260911に外側foldの0始まり番号を加算). 内側開発側だけで各手法のパラメータを選び, 内側評価側の予測を集




図2 調整済み BM25 に対する正解順位の改善・悪化率。順位不変は省略した。カテゴリ条件付き Query2doc 型は正解カテゴリを利用する。誤差棒は根拠文書単位の 95% クラスタ・ブートストラップ区間（多重比較未調整）。

表6 外側 5-fold・内側 4-fold によるルーティング。カテゴリ別選択は正解カテゴリ既知。候補 5 手法は正解カテゴリありの拡張を含む。Oracle は実運用性能ではない。

方式	MRR	R@1	R@3	R@5	R@10
単一手法選択	0.8422	81.2	85.1	87.3	90.2
カテゴリ別選択（正解カテゴリあり）	0.8387	81.2	85.1	85.5	89.5
質問単位 Oracle	0.8703	84.4	88.8	89.9	90.9

約した MRR から、全体で一つの手法、またはカテゴリごとの手法を選ぶ。その後、選択手法のパラメータを外側開発集合で選び直し、外側評価集合へ適用した。従って表4の特定手法の行と、表6の単一手法選択の行が一致する必要はない。カテゴリは正解ラベルを用いる分析条件であり、カテゴリ推定の誤りは含まない。候補集合にも正解カテゴリを入力する拡張方式が含まれる。

カテゴリ別選択の MRR は 0.8387 で、単一手法選択の 0.8422 を下回った。カテゴリ情報だけでは、質問ごとに適した検索手法を安定して選べなかった。5 候補から各質問に最も適した手法を選ぶ Oracle の MRR は 0.8703 であった。これは、候補手法の結果を質問ごとに見た場合に到達できる上限を表す。実運用では正解順位を事前に知らないため、カテゴリ別選択との差は、カテゴリ以外の検索情報を利用する余地を示している。

6 考察と限界

6.1 省略による性能低下と手法差

元質問から省略質問にすると、生成を伴わない 5 手法で MRR が低下した。省略によって固有名詞や日付などの明確な検索信号が失われるため、検索器の種類にかかわらず正解ページを特定しにくくなったと考えられる。一方、低下幅は手法によって異なり、密検索の低下が大きいものに対し、BM25 や疎密統合の低下は比較的小さかった。省略後も残

る文字列の一致を利用できたことと、疎検索・密検索の異なる信号を組み合わせることが理由として考えられる。

重み付き疎密統合は省略質問の平均 MRR で最も高く、疎検索と密検索の組合せが有力な候補となった。ただし、元質問でも同じ方式が BM25 を上回っており、省略時だけに現れる頑健性とはいえない。これは、省略への対策として特別な方式を導入する前に、通常の検索信号を適切に組み合わせることが重要であることを示唆する。カテゴリ別の差はカテゴリごとの質問数が限られるため、図1の値を傾向の参考として解釈する。

6.2 クエリ拡張で生じる改善と悪化

クエリ拡張 3 方式では、正解順位が改善する質問と悪化する質問の両方が見られた。拡張語が省略後の不足した検索信号を補う場合は順位が上がる一方、質問にない具体的な語や一般語が加わると、検索対象がずれて順位が下がると考えられる。一部の失敗には、この語彙のクエリドリフトが関与した可能性がある。

同じ疑似文書を用いて質問語の重みだけを 1 から 5 へ変更すると MRR が上昇した。元の質問語を強く残すことで、生成文に含まれる一般的な説明語が検索結果を支配することを抑えられたと考えられる。一方、通常版とカテゴリ条件付き版の差には、カテゴリ情報の効果と生成文の違いが混在しているため、カテゴリ情報だけの効果は分離できない。

6.3 カテゴリ別手法選択の限界

カテゴリ別の手法選択は単一手法選択を上回らなかった。同じカテゴリ内でも、省略された語の具体性や残った質問語、根拠ページの文体が異なるため、カテゴリだけでは質問ごとの適切な手法を決める情報として不十分だったと考えられる。質問単位 Oracle との開きは、検索器間のスコア差や上位文書の一致度など、カテゴリ以外の情報を用いる余地を示している。

6.4 限界

限界は、データと評価、生成と実装、結果の一般化の三点に整理できる。第一に、データと評価は JDocQA 由来の 510 文書と、人手評価で選別した 276 質問に限られる。自然性・回答可能性に問題のある 30 件を除外しており、カテゴリごとの件数も 32–49 件である。評価では元質問に付与された一つの根拠ページを正解とし、他ページの適合性や省略後質問の別解釈は判定していない。

第二に、生成と実装には条件依存がある。格省略と意味役割省略で生成方法と入力情報が異なり、追加監査では指定範囲以外の削除や回答対象の変化も確認された。Query2doc 型もモデル、プロンプト、生成文、文字 bigram 化が本研究固有の設定であり、保存済み生成文の完結状態は記録されていない。

第三に、結果の一般化には限界がある。パラメータ選択は有限の開発データと候補範囲に基づき、統計的な推論は保存済みの評価側予測に条件付く。異なる文書集合、検索器、生成条件で同じ傾向が得られるかは今後の検証が必要である。

7 おわりに

日本語の省略質問 306 候補を生成し、人手評価で 276 件を選別した。510 一意文書を対象に 7 手法を比較した結果、RQ1 では生成を伴わない 5 手法すべてで元質問から省略質問への平均 MRR 低下を確認した。RQ2 では重み付き疎密統合が平均 MRR 0.8460 で最高となり、疎検索と密検索の組合せが有力な候補となった。ただし、その差は本データと実装条件に基づく結果として解釈する。また、主比較のクエリ拡張 3 方式で検索結果の改善と悪化の両方が見られ、その和集合では Top-1 回復 7 件、悪化 8 件であった。補助分析では、同じ疑似文書でも質問語の重み付けによって Query2doc 型の検索性能が変化することを確認した。RQ3 では内側検証を用いた省略カテゴリ別の検索手法選択が全カテゴリ共通の検索手法選択を上回る証拠は得られなかった。本稿の知見は、人手選別した本データにおける単一根拠ページの再発見と各実装条件に限定される。追加監査は編集内容と省略記録、生成文の完結性を区別して管理する必要も示したが、研究者による独立した再判定は今後の課題である。今後は生成条件の対照実験、より大規模な文書集合での検証、評価基準の明確化を進め、情報不足を検知して補完や確認質問へ接続する処理を検討する。

参考文献

- [1] Nasreen Abdul-Jaleel, James Allan, W. Bruce Croft, Fernando Diaz, Leah S. Larkey, Xiaoyan Li, Mark D. Smucker, and Courtney Wade. UMass at TREC 2004: Novelty and HARD. In *Proceedings of the Thirteenth Text REtrieval Conference*, volume 500-261 of *NIST Special Publication*, 2004.
- [2] Gordon V. Cormack, Charles L. A. Clarke, and Stefan Büttcher. Reciprocal rank fusion outperforms condorcet and individual rank learning methods. In *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 758–759, 2009.
- [3] Nick Craswell, Bhaskar Mitra, Emine Yilmaz, Daniel Campos, and Ellen M. Voorhees. Overview of the TREC 2019 deep learning track. In *Proceedings of the Twenty-Eighth Text REtrieval Conference*, volume 1250 of *NIST Special Publication*, 2020.
- [4] Andrew F. Hayes and Klaus Krippendorff. Answering the call for a standard reliability measure for coding data. *Communication Methods and Measures*, 1(1):77–89, 2007.
- [5] Yukiko Ishizuki, Tatsuki Kuribayashi, Yuichiro Matsubayashi, Ryohei Sasano, and Kentaro Inui. To drop or not to drop? predicting argument ellipsis judgments: A case study in Japanese. In *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation*, pages 16198–16210. ELRA and ICCL, 2024.
- [6] Vladimir Karpukhin, Barlas Oguz, Sewon Min, Patrick Lewis, Ledell Wu, Sergey Edunov, Danqi Chen, and Wen-tau Yih. Dense passage retrieval for open-domain question answering. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*, pages 6769–6781, 2020.
- [7] Victor Lavrenko and W. Bruce Croft. Relevance-based language models. In *Proceedings of the 24th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 120–127, 2001.
- [8] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems*, volume 33, pages 9459–9474, 2020.
- [9] Tri Nguyen, Mir Rosenberg, Xia Song, Jianfeng Gao, Saurabh Tiwary, Rangan Majumder, and Li Deng. MS MARCO: A human generated MACHine reading COMprehension dataset. In *Proceedings of the Workshop on Cognitive Computation: Integrating Neural and Symbolic Approaches*, volume 1773 of *CEUR Workshop Proceedings*, 2016. Paper 9.
- [10] Eri Onami, Shuhei Kurita, Taiki Miyanishi, and Taro Watanabe. JDocQA: Japanese document question answering dataset for generative language models. In *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation*, pages 9503–9514, 2024.
- [11] Stephen Robertson and Hugo Zaragoza. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389, 2009.
- [12] Ryohei Sasano and Sadao Kurohashi. A discriminative approach to Japanese zero anaphora resolution with large-scale lexicalized case frames. In *Proceedings of the 5th International Joint Conference on Natural Language Processing*, pages 758–766. Asian Federation of Natural Language Processing, 2011.
- [13] Nandan Thakur, Nils Reimers, Andreas Rücklé, Abhishek Srivastava, and Iryna Gurevych. BEIR: A heterogeneous benchmark for zero-shot evaluation of information retrieval models. In *Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks*, volume 1, 2021.

- [14] Nobuhiro Ueda, Kazumasa Omura, Takashi Kodama, Hirokazu Kiyomaru, Yugo Murawaki, Daisuke Kawahara, and Sadao Kurohashi. KWJA: A unified Japanese analyzer based on foundation models. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 3: System Demonstrations)*, pages 538–548, 2023.
- [15] Liang Wang, Nan Yang, and Furu Wei. Query2doc: Query expansion with large language models. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 9414–9423, 2023.
- [16] 佐々木 峻・山本 大輝. 日本語 RAG 検索における省略由来の曖昧クエリ検知. In *言語処理学会第 32 回年次大会発表論文集*, pages 778–782, 2026.

付録 A 意味役割 4 カテゴリ生成プロンプトの要約

以下は 4cat-role-exclusive-v5 の説明用要約であり、実使用文字列の逐語掲載ではない。システム指示、カテゴリ定義・編集例、入力作成関数、JSON schema と構造化出力設定を補足資料に収録した（付録 G）。入力には PDF 名・カテゴリ・ページ、元質問、正解回答、根拠本文の先頭 3,000 文字を含める。人物・組織は行為者・運営者・所有者等、時間は明示的な年度・日付・期間等、場所・管轄は所在地・適用地域等、対象・内容・属性は他の 3 カテゴリに該当しない制度・事業・条件・数量等と定義する。自治体名等は語種ではなく元質問中の意味役割で区別する。元質問に明示された省略対象のみの削除と、必要最小限の文法調整を指示し、語順・述語・問いの焦点の変更、言い換え、情報追加を禁止する。カテゴリを一意に決められない場合や大幅な修正を要する場合は impossible とする。各カテゴリの ID, ok/impossible, 省略後質問, 省略情報, 理由と、主要カテゴリを JSON で返す。これは生成時の指示であり、出力が必ず遵守したという意味ではない。また実プロンプトには「情報十分性や単独での検索可能性は後段で人手評価する」との文言があるが、実際の配布ガイドの回答可能性は文書特定済みの仮定である。本稿は後者の実施内容に基づいて評価を説明する。

付録 B Query2doc 型拡張の日本語プロンプトの要約

Query2doc 型は gpt-5-mini と日本語 4-shot（付録 B）で生成した疑似文書を用いる。最大出力 256 token, temperature・seed は未指定である。作業記録上、生成は 2026 年 8 月 2 日までに完了した。ただし各応答の実行日時と解決後の snapshot ID は保存されておらず、キャッシュのモデル表記は別名 gpt-5-mini のみである。生成の厳密な再現には限界があるが、本稿の再検索では保存済み生成文を固定した。元質問、正解回答、根拠文書、実際の削除文字列は入力せず、カテゴリ条件付き版だけに正解カテゴリ名と定義を与える。

プロンプトは固有名詞・数値・日付を推測で断定することを抑制し、4-shot も一般的な説明文からなる。従って原研究 [15] とはモデル、生成長、例示、具体化への制約が異なる。カテゴリ条件付き版は正解カテゴリ既知の分析条件であり、質問のみからカテゴリを推定する性能は評価していない。保存文の完結性と受付処理の限界は付録 E に示す。

以下も説明用要約である。実文字列は句読点・改行を含め補足資料へ保存した。システム指示は、与えられた質問から検索対象にありそうな短い疑似文書だけを日本語で出力することを求める。4-shot は「利用できる時間帯」「申請に必要なもの」「開催場所」「運営主体」の 4 質問に対し、それぞれ受付時間等、必要書類等、会場・アクセス等、担当組織等を説明する一般的な疑似文書を例示する。実質問への指示は、検索対象にありそうな語句を含む 100～200 字の疑似文書の一つ作ること、固有名詞・数値・日付を推測で断定せず関連する説明語・検索語を加えること、本文のみを出力することである。条件付き版には正解カテゴリの名称と定義、その種類の情報を補う検索語を含める指示を追加する。100～200 字は依頼であり、実出力の長さを保証しない。最大 256 token という出力上限とも異なる。

付録 C 省略質問の実例

評価用 276 件から選んだ実例を示す。元質問と省略後質問は保存データの文字列を掲載し、削除範囲は両文字列から確認した。カテゴリは既存の付与ラベルであり、情報損失や分類の適切さを保証するものではない。

表 7 元質問と省略後質問の実例。既存ラベルと編集内容の注意点を併記する。

ガ格 (EVAL-0049)	
元質問	分別資源ごみの収集で、1 月 5 日に収集日が変更された地区はどこですか？
省略後	分別資源ごみの収集で、1 月 5 日に変更された地区はどこですか？
削除範囲	収集日が
定義・注意	動作・状態の主体
ヲ格 (EVAL-0057)	
元質問	新成人のつどいで利用する駐車場について、100 台駐車できる市環境部の駐車場はどのような人に利用を呼び掛けていますか？
省略後	新成人のつどいで利用する駐車場について、100 台駐車できる市環境部の駐車場はどのような人に呼び掛けていますか？
削除範囲	利用を
定義・注意	動作の対象
二格 (EVAL-0147)	
元質問	東京都薬物乱用防止推進港区協議会主催の薬物乱用防止ポスター・標語コンクールにおいて、ポスターの部で地区優秀賞に選ばれた高松中学校生徒の作品はどのような作品でしょうか？
省略後	東京都薬物乱用防止推進港区協議会主催の薬物乱用防止ポスター・標語コンクールにおいて、ポスターの部で選ばれた高松中学校生徒の作品はどのような作品でしょうか？
削除範囲	地区優秀賞に
定義・注意	相手・到達点・対象
人物・組織 (EVAL-0095)	
元質問	消防本部の応急手当の講習（救命講習）のうち「上級救命講習」はいつ、どこで開催されますか？
省略後	応急手当の講習（救命講習）のうち「上級救命講習」はいつ、どこで開催されますか？
削除範囲	消防本部の
定義・注意	行為者・運営者・情報源
場所・管轄 (EVAL-0018)	
元質問	田子の浦港で水揚げされる主な魚であるシラスは、どのような見た目をしていますか？
省略後	水揚げされる主な魚であるシラスは、どのような見た目をしていますか？
削除範囲	田子の浦港で
定義・注意	地域・所在地・会場
時間 (EVAL-0026)	
元質問	バスやトラック運転手の高齢化に関して、バス・トラック運転手の年齢構成比 (2018 年時点) のグラフでの大型トラック運転手の年齢構成はどうなっていますか？
省略後	バスやトラック運転手の高齢化に関して、バス・トラック運転手の年齢構成比のグラフでの大型トラック運転手の年齢構成はどうなっていますか？
削除範囲	(2018 年時点)
定義・注意	年度・日付・期間・時刻
対象等 (EVAL-0036)	
元質問	神栖市の大野原小学校区地域コミュニティ協議会では、11 月 11 日にどのような防災訓練が行われたのでしょうか？
省略後	神栖市の大野原小学校区地域コミュニティ協議会では、11 月 11 日にどのような訓練が行われたのでしょうか？
削除範囲	防災
定義・注意	「防災訓練」のうち「防災」のみを削除。管理表の記録は「防災訓練」で範囲が異なる

対象等 (EVAL-0041)	
元質問	令和 2 年度の海外試験結果でインドネシア、タイ、フィリピンでの総合合格率が最も高い国とその合格者数はどうなっていますか？
省略後	令和 2 年度の海外試験結果でインドネシア、タイ、フィリピンでの総合合格率が最も高い国はどうなっていますか？
削除範囲	とその合格者数
定義・注意	求める回答項目も減少。純粋な識別情報の削除とは区別が必要

付録 D 生成方式別の一致度と削除記録の監査

以下は初回 3 名による人手評点の順序尺度 α である。生成方式間の差は評点分布や対象質問の違いにも依存する。

方式	評価軸	件数	α	ペア一致率 (%)
格省略	自然性	120	0.5107	57.2
格省略	回答可能性	120	0.3044	56.1
意味役割	自然性	186	0.2536	75.8
意味役割	回答可能性	186	0.4211	54.3
意味役割	カテゴリ妥当性	186	0.1048	83.2

表 8 生成方式別の初回一致度。

削除記録を 276 件すべてで照合すると、191 件は記録文字列の 1 箇所削除で省略後質問を再現でき、85 件は再現できなかった。この 85 件を対象に、Codex による全文確認と、コードによる編集範囲の再構成・出典照合を追加した。以下の意味分類は AI による単独監査であり、研究者の再アノテーションや複数判定者の合意ではない。検索順位を監査一覧へ含めなかったが、先行する感度分析結果は既知であり、完全な盲検でもない。

85 件のうち 52 件は記録範囲に付随する助詞・句読点・接続表現の調整のみと分類し、33 件にはその他の所見を付けた。所見は重複し、同カテゴリの複数箇所削除 4 件、記録範囲と実削除の差 8 件、別内容の追加削除 4 件、回答対象・比較軸の変化 5 件等を含む。33 件すべてを不適切とは判定していない。文字単位では 83 件が削除のみ、2 件が置換等を伴い、全編集範囲の適用により 85 件すべてを再構成できた。元質問・省略後質問は 85 件すべて生成ログ、管理表、最終データ間で一致した。一方、省略情報は 57 件が逐語一致し、28 件が異なったが、既存の記録加工処理ですべて再現できた。例えば EVAL-0017 は生成ログに「生徒から見た」「学校・教員から見た」の両方がある一方、管理表には後者だけが残る。EVAL-0036 では「防災」の削除が「防災訓練」として記録される。すべての記録不一致を生成時の誤りとは説明できない。

これに対し EVAL-0061 の大会の前置き、EVAL-0189 の公売に関する前置き、EVAL-0257 の施設・休業期間を述べる前文の追加削除は、生成時から存在する。また EVAL-0300 の「日時はいつ」から「のはいつ」への変更は意味を保つ可能性がある。記録一致の 191 件も含め、文字列の短縮だけでは意味的な情報不足を保証できない。本監査でデータの採否・ラベル・検索結果を変更していない。全編集範囲、元の省略記録、加工後記録を分離して保持し、今後の研究者による確認につなげる。

付録 E 保存生成文の品質監査

通常版 276 件と正解カテゴリあり版 276 件の計 552 件を Codex が全文確認した。この分類も単独の AI 監査であり、事実性や検索有効性の人手評価ではない。

生成条件	明瞭な中断なし	強い中断兆候	列挙とも読める	100 字未満	200 字超
通常	272	3	1	14	0
正解カテゴリあり	273	1	2	5	1

表 9 現行保存生成文の監査。長さの逸脱と中断候補は重複する。

強い中断兆候は通常版 EVAL-0094（完結文の後の「保護」）、0235（「概要や関連」）、0262（「人材・設備の」）、条件付き版 0029（「調」）である。通常版 0232、条件付き版 0018・0045 は列挙としても読めるため、判定に幅を残した。句点のない検索語列を一律に未完とはしない。受付処理は 50 字以上かを確認していたが、API 完了状態は保存せず、独自の status=ok を付けていた。従って出力上限による打ち切りを原因と断定できない。旧通常版キャッシュ 276 件も照合し、現行と同じ 272 件を本文一致で対応付け、異なる 4 件を全文確認した。後者は短い未完文だったが現行主結果には使われていない。保存 828

レコードは条件・ID・本文の版として 556 件に対応する．本稿の再検索は現行キャッシュを維持し，新たな API 生成は行っていない．今後は受付時に応答の完了状態・実行日時・解決後モデル名・使用量を保存し，文面の完結性と別に管理する必要がある．

付録 F 探索的な感度分析

保存済み候補順位を用いた補助分析を示す．中断候補 7 質問の除外は全手法共通で，元の外側分割を保ち，各開発・評価側から該当 ID を除いてパラメータを選び直した．元質問等重みの条件は，再調整せず，同一元質問からの派生質問の逆数順位を平均した後，176 元質問で平均した．

条件	BM25	疎密統合	Query2doc 型	正解カテゴリあり
現行 276 件	0.8333	0.8460	0.8382	0.8447
中断候補 7 質問を共通除外 (269 件)	0.8364	0.8492	0.8443	0.8477
176 元質問を等重み (再調整なし)	0.8279	0.8422	0.8364	0.8397

表 10 補助条件の MRR. 主結果の置換や最終採否の選択には用いない.

さらに seed 20260916~20260935 で根拠文書単位の 5 分割を 20 通り作り直し，各開発側で再調整すると，疎密統合の MRR は 0.8404~0.8515 で，20 通りとも平均 MRR 最高だった．BM25 は 0.8196~0.8350 だった．今回の 176 元質問，176 正解ページ，176 正解 PDF は一対一であり，PDF 単位とページ単位は同じグループとなる．20 通りは独立した 20 標本ではなく，有意差や一般化の証明とはしない．品質問題が解消したことも意味しない．

付録 G 再現資料と公開版との対応

公開リポジトリには，本稿に対応する検索・分析コード，保存済みの実験結果と候補順位，生成済み疑似文書，プロンプトの実文字列・入力作成関数・JSON schema，および結果の照合手順を収録している．旧結果は過去版として区別し，本稿の主結果は訂正後の評価結果を参照する．保存コードから復元した入力は，過去の API 送信内容を完全に記録した通信ログとは異なる．保存順位に基づく結果の照合と統計分析は API を使わず実行できる．検索スコアからの再計算には JDocQA 由来のコーパスと埋め込みが必要であり，元 PDF・コーパス本文・埋め込みキャッシュは再配布していない．評価者識別子と品質監査上の注意点は公開資料に記載した．

付録 H 評価設定と統計処理の詳細

H.1 検索対象と分割

検索対象 510 文書は，文書 ID, (PDF 名, ページ), 本文完全一致の各基準で一意であり，NFKC 正規化・小文字化・空白除去後の本文にも重複はない．これは近似した文書の不存在を意味しない．本文の総文字数 592,935 は，JSON 復号後の Unicode 文字列長の合計である．分割 seed は 20260802 とした．省略後の他ページの適合性は再判定していないため，別の妥当な解釈に対応するページも本評価では正解に含まれない．

H.2 探索範囲と統計処理

主比較では密検索以外の各手法を開発側で調整する．BM25 の $k_1 \in \{0.6, 1.2, 1.8, 2.4\}$, $b \in \{0, 0.25, 0.5, 0.75, 1\}$ の 20 候補を共通に用いる．RM3 型はさらに質問分布の補間重み $\{0.25, 0.5, 0.75\}$ と拡張語数 $\{5, 10, 20\}$ を組み合わせた 180 候補，RRF は $k \in \{10, 30, 60, 100\}$ との 80 候補，重み付き疎密統合は $\alpha \in \{0, 0.1, \dots, 1\}$ との 220 候補である．Query2doc 型 2 方式は $n = 5$ を固定し 20 候補とする．同点 MRR は固定値を優先する決定的な候補順で解決する．選択を行う場所は揃えるが，探索候補数は等しくなく，等予算の比較ではない．補助比較では $k_1 = 1.2, b = 0.75$ 等を固定する．これらの追加設定は査読後の検証として定めたもので，研究全体の事前登録ではない．

同じ根拠文書の質問を一括して符号反転する両側対応あり検定を 100,000 回行い，95% 信頼区間は同単位のクラスターブートストラップ 100,000 回で算出する (seed 20260911)．主比較の 6 手法対 BM25 の MRR 検定を一つの比較族として Holm 補正する．MRR を主指標にするだけでは手法方向の多重性は解消しないためである． $R@k$ は記述統計として示す．また省略質問と元質問のそれぞれで BM25 に対する MRR 利得を求め，その差を省略と手法の交互作用として比較する．生成を伴わない 4 手法対 BM25 を別の比較族とする．推論は保存済み評価側予測に条件付けたもので，ブートストラップ内でパラメータ選択自体は再実行しない．選択過程の不確実性をすべて含むものではない．図の信頼区間も同じ条件付き推論であ

る。非有意は同等性や効果の不存在を示さない。